

CTR-GCN 双流基线复现：3 次重复实验

NTU120 Interaction-26 (CSub) · joint 与 bone 双流 · 3 个随机种子各训练一次，共 6 次完整训练 · 含每类与混淆分析 · 2026-09-20

双流融合 test Top-1，3 次重复实验

91.20 ± 0.17


百分点，极差 0.30 pp

一 实验设置与融合结果

在完全相同的配置下用 3 个随机种子各完整训练一次 joint 流与 bone 流，共 6 次训练，逐对做分数级融合，以测量该基线在重复实验下的取值范围。融合方式为 joint 与 bone 分数 1:1 等权求和。

表一 各次实验的配对融合结果 (joint_seedN + bone_seedN)

种子	融合 test Top-1	融合 test Top-5
seed 1	91.11%	98.82%
seed 2	91.40%	98.87%
seed 3	91.10%	98.84%
均值 ± 标准差	91.20 ± 0.17	98.84 ± 0.03



二 单流：joint 与 bone

joint 为 88.28 ± 0.20 pp (88.10–88.49) ，bone 为 88.57 ± 0.40 pp (88.33–89.03) ，两者范围重叠。三次实验中两条流的排序并不一致：一次 joint 高 0.16 pp，另两次 bone 分别高 0.77 pp 和 0.27 pp。bone 均值上的 0.29 pp 优势来自其中一次 (seed 2) ——去掉该次后 joint 88.29、bone 88.34，相差 0.05 pp。两条流的单流精度在本子集上不可区分，任何一次实验内部的高低均不足以判定优劣。

表二 6 次训练的验证与测试结果 (test Top-1 / Top-5 由保存的 score 文件重算，与训练日志逐位一致)

种子	流	val 最佳 Top-1	最佳 epoch	test Top-1	test Top-5
seed 1	joint	94.42%	60	88.49%	98.37%
seed 1	bone	93.81%	55	88.33%	98.20%
seed 2	joint	94.27%	56	88.26%	98.34%
seed 2	bone	94.42%	59	89.03%	98.28%
seed 3	joint	94.04%	54	88.10%	98.16%
seed 3	bone	93.58%	56	88.36%	98.38%
joint 均值 $\pm$ 标准差		94.24 $\pm$ 0.19	54–60	88.28 $\pm$ 0.20	98.29 $\pm$ 0.11
bone 均值 $\pm$ 标准差		93.93 $\pm$ 0.43	55–59	88.57 $\pm$ 0.40	98.29 $\pm$ 0.09

三 与 V1 报告的对照

seed 1 这次训练的结果此前已作为 V1 报告发布。三次融合结果 (91.10 / 91.11 / 91.40) 的中位数即 91.11，与 V1 报告的数字相同，该次实验在三次中处于中间位置。均值 91.20 包含 91.11 在内，两者不构成提升关系，只是同一基线附上了误差范围。

按第二节的结果，V1 报告中 joint 优于 bone 的比较不再成立；融合主数字与评估方法不受影响。

四 方差比较

融合的标准差为 0.17 pp，低于 bone 单流的 0.40 pp 和 joint 的 0.20 pp。单流上偏高的一次 (seed 2 的 bone，高出 bone 均值 0.46 pp) 在融合后仅高出融合中位数 0.29 pp。相对当次较好的单流，三次的融合增益为 +2.62、+2.37、+2.74 pp。

五 验证集与测试集

val 准确率系统性高于 test：joint 高 5.93–6.01 pp，bone 高 5.22–5.48 pp，两者绝对数值不可直接比较。排序方面，joint 三次的 val 排序 (94.42 > 94.27 > 94.04) 与 test 排序 (88.49 > 88.26 > 88.10) 一致；bone 有一处 0.03 pp 的倒挂 (val 上 seed 1 高于 seed 3，test 上为 88.33 对 88.36)。val 的绝对值不构成性能估计，其排序信号与按 val Top-1 选取 checkpoint 的做法相符。

六 噪声阈值

本次 3 轮实验仅随机种子不同，融合结果的极差为 0.30 pp。因此低于 0.3 pp 的融合涨幅无法与种子噪声区分，判断一个改动是否有效需要在多个种子上比较两组的均值与范围，而非单次结果之间的对比。

七 每类正确率与每类噪声阈值

同样的判据在类别层面要严得多。每类测试样本只有 273–576 个，单类正确率的抽样标准差 $\sqrt{p(1-p)/n}$ 为 0.21–1.99 pp（中位 1.13 pp），对应的 2σ 阈值为 0.42–3.97 pp，随该类正确率与样本数变化。三次实验的每类实际极差与此同量级：joint 中位 2.08 pp、最大 7.83 pp，bone 中位 2.43 pp、最大 6.52 pp，fusion 中位 1.56 pp、最大 3.99 pp。

因此整体层面的 0.3 pp 阈值在这里不适用。以下每类层面的比较一律对照各类自身的 2σ 阈值，未超过的标为噪声，不作解释。


表三 每类 test 正确率（3 次实验平均），按 fusion 均值升序

类别	joint 均值	bone 均值	fusion 均值	fusion 三次极差 (pp)
类 11	59.25%	63.07%	65.28%	3.13
类 12	61.69%	63.48%	67.19%	3.30
类 15	64.12%	72.23%	75.83%	2.96
类 6	86.23%	88.65%	89.37%	1.45
类 22	89.04%	84.00%	90.32%	0.87
类 4	86.72%	87.08%	91.18%	1.45
类 14	87.19%	87.42%	91.54%	2.43
类 0	88.44%	87.47%	91.61%	3.65
类 13	87.79%	86.98%	91.96%	3.65
类 1	92.51%	89.73%	93.24%	2.90
类 3	89.73%	88.41%	93.24%	2.54
类 24	91.54%	90.61%	93.51%	2.43
类 23	92.06%	93.97%	94.26%	2.43
类 21	91.96%	91.20%	94.68%	3.99
类 16	92.81%	92.17%	95.01%	1.22
类 7	92.48%	93.21%	95.15%	2.55
类 10	95.53%	89.25%	95.17%	1.09
类 20	93.23%	93.06%	95.72%	1.56
类 2	96.01%	93.60%	96.50%	1.45
类 8	95.65%	95.53%	96.50%	1.09
类 25	96.93%	97.63%	97.63%	0.69
类 19	97.11%	98.67%	98.44%	0.52
类 17	96.76%	98.15%	98.90%	0.52
类 5	99.39%	98.66%	99.51%	1.09
类 18	98.32%	99.01%	99.59%	0.35
类 9	99.51%	98.17%	99.88%	0.37

类 11、12、15 是最难的三类（fusion 均值 65.28%、67.19%、75.83%），与其余 23 类拉开明显距离；最高的类 9、18、5 均在 99% 以上。

八 混淆结构


下图为 fusion 的混淆矩阵，按行归一化（每行除以该类样本数，消除各类样本数差异），三次实验取平均，对角线置零以便观察错分去向。



表四 最易混方向（fusion，3 次平均的行归一化混淆，非对角线前 15）

方向（真值 → 预测）	占该类样本	约合样本数	双向互混
类 11 → 类 12	9.57%	55	是
类 11 → 类 0	9.45%	54	—
类 12 → 类 11	8.16%	47	是
类 15 → 类 4	7.42%	43	—
类 15 → 类 20	6.67%	38	—
类 6 → 类 23	5.07%	14	是
类 23 → 类 6	4.75%	27	是
类 21 → 类 10	4.28%	25	—
类 15 → 类 12	4.00%	23	是
类 12 → 类 15	3.82%	22	是
类 12 → 类 0	3.59%	21	—
类 12 → 类 13	3.53%	20	—
类 4 → 类 3	3.38%	9	—
类 22 → 类 13	3.19%	18	—
类 12 → 类 4	2.89%	17	—

错分是不对称的，表中按方向分别列出。三对呈双向互混：类 11 与类 12、类 12 与类 15、类 6 与类 23。类 11 的错分同时流向类 12（9.57%）和类 0（9.45%），是两个方向上都最重的一类。



三次实验各自的矩阵（同一色阶）结构一致，上述混淆模式不随种子改变。

九 融合在类别层面的作用

逐类比较 fusion 与 max(joint, bone) 的 3 次平均值，并对照各类的 2σ 门槛。

表五 fusion 相对 max(joint, bone) 的每类变化 (pp, 3 次平均)，提升最大与下降最大各 6 类

类别	平均变化	三次分别	2σ 门槛	判定
类 13	+4.17	+3.99 / +4.17 / +3.12	2.27	超出门槛
类 14	+4.12	+4.70 / +3.30 / +4.35	2.32	超出门槛
类 4	+4.11	+3.26 / +3.26 / +4.35	3.41	超出门槛
类 12	+3.70	+2.60 / +2.78 / +2.78	3.91	门槛内 (噪声)
类 15	+3.59	+1.74 / +5.57 / +3.48	3.57	超出门槛
类 3	+3.50	+1.45 / +3.62 / +4.71	3.02	超出门槛
类 9	+0.37	+0.00 / +1.10 / +0.00	0.42	门槛内 (噪声)
类 23	+0.29	+0.70 / -0.35 / +0.52	1.94	门槛内 (噪声)
类 5	+0.12	+0.00 / -0.36 / +0.36	0.84	门槛内 (噪声)
类 25	+0.00	+0.35 / -0.17 / -0.17	1.27	门槛内 (噪声)
类 19	-0.23	-0.35 / +0.00 / -0.35	1.03	门槛内 (噪声)
类 10	-0.36	-1.81 / +1.45 / -0.72	2.58	门槛内 (噪声)

提升超过门槛的有类 13、14、4、15、3 (+4.17、+4.12、+4.11、+3.59、+3.50 pp)，其中类 15 仅勉强超过 (3.59 对门槛 3.57)；类 12 的 +3.70 pp 未达其 3.91 pp 的门槛。下降一侧没有任何一类超过门槛：绝对值最大的类 10 为 -0.36 pp，门槛 2.58 pp，三次分别为 -1.81、+1.45、-0.72 pp，符号都不一致。三次平均后，没有证据表明融合会让任何一类变差。

V1 单次结果报告的三处下降在三次平均后均不成立：类 10 单次 -1.81 pp，三次平均 -0.36 pp (门槛 2.58)；类 2 单次 -1.45 pp，三次平均 +0.48 pp (门槛 2.21)；类 19 单次 -0.35 pp，三次平均 -0.23 pp (门槛 1.03)。三者均在噪声范围内，V1 中这三条结论不成立。

融合增益与 joint、bone 两条流的分歧率 (同一样本两流预测不同的比例，各类为 1.8%–40.1%，中位 11.4%) 呈正相关，皮尔逊相关系数 $r = 0.62$ ；而与两流正确率之差几乎无关 ($r = -0.10$)。即融合的收益来自两流在哪些类上判断不一致，而不是来自哪条流在该类上更强。

十 限制

- 本次测得的波动是真实波动的下界。DataLoader 的 `worker_init_fn` 将每个 worker 的随机种子设为 worker 编号 0–3，与 `--seed` 无关，因此数据增强 (随机旋转、随机裁剪) 的随机性在三次实验中相同，仅模型初始化与批次打乱顺序随种子改变。此行为来自原版 CTR-GCN，非本项目引入。
- 重复次数为 3，标准差本身的不确定性较大，仅可用于判断 0.3 pp 量级的差异，故同时给出极差。

- 9 种 joint-bone 交叉组合的融合也已计算，但从九个组合中挑选最高值等于在测试集上选模型，违反评估协议，故不报告。
- 每类结果的噪声门槛远高于整体。各类 2σ 门槛为 0.42–3.97 pp，不能用整体层面的 0.3 pp 去衡量每类数字。
- 类别保持数字编号 0–25。生成该 26 类子集的脚本与子集文档均不在本服务器上，无法确认单个索引对应的动作名；由 `statistics/label.txt` 与 CSub 协议复算的每类样本数可确认子集为 A50–A60 与 A106–A120 共 26 类，但计数在类间有重复，不足以钉死每个索引，故不使用动作名。
- 结论限于 NTU120 Interaction-26 (CSub) 子集及当前超参数。

十一 方法与校验

6 次训练配置一致 (device [0,1] 双卡、65 epoch、base_lr 0.1、step [35,55])，仅 `--seed` 与 `--work-dir` 不同，未修改 yaml 或代码。每次训练约 1 小时 55 分，6 次总时长极差不到 1 分钟。

seed 1 的指标由分析脚本在其已有产物上复算，joint、bone、融合三个数与 V1 报告的 `metrics_summary.json` 完全一致；该次实验的两个目录在本次新增训练前后，228 个文件的 mtime、大小及关键文件 md5 均未变化。

结果文件：`reports/seedvar_s2s3/seedvar_results_seeds1_2_3.json`（本报告数字的唯一来源）、`seedvar_results_seeds1_2_3.md`、`analyze_seedvar.py`。

训练产物：

`work_dir/ntu120_interaction26/csub/ctr_gcn_{joint,bone}_server{,_seed2,_seed3}/`，其中无后缀的两个目录为 seed 1 (V1 已发布的那次)，未改动。

```
cd /mnt/data/6008/CTR-GCN
python main.py --config config/ntu120-interaction26-csub/joint_server.yaml --phase train \
  --seed 2 --work-dir ./work_dir/ntu120_interaction26/csub/ctr_gcn_joint_server_seed2
python reports/seedvar_s2s3/analyze_seedvar.py 1 2 3
```

6 次完整训练 (3 个种子 × 2 条流，每次 65 epoch)。差值均以百分点 (pp) 表示。重复次数为 3，未做显著性检验。